

DS Mini Project | DAY 1 모델 전략 수립

초기 100 사이클로 ESS 배터리 수명을 예측한다

MIT-Stanford Battery Dataset (Severson et al., Nature Energy 2019), Batch 1, 2, 3 EDA와 모델링 전략

선택 태스크

Regression

초기 100 사이클 → cycle life

Target Variable

log10(cycle_life)

EOL = 방전 용량 0.88Ah (SOH 80%)

목표 성능 (원논문)

MAPE 9.1%

Train Batch 1 → Test Batch 2

울산 2반 | 김영제, 김지훈 2026.10.01

셀별 교체 시점을 운영 초기 데이터로 미리 안다

ISSUE) ESS는 배터리 교체 비용이 CAPEX의 30~40%다. 교체 시점을 모르면 돌발 중단이나 과잉 교체로 비용이 커진다.

Task : Regression

- 셀별로, 초기 100 사이클 데이터로, EOL까지의 총 사이클 수를 예측
- 가장 강한 신호($\Delta Q(V)$, Q3)는 cycle 100 정보가 필요 → 5 사이클 Classification에서는 쓸 수 없다
- Classification(550 기준) 라벨은 b1 36셀 중 단명 1셀뿐(97.2%가 장수) → 학습 불가
- "몇 사이클 남았나"가 교체 계획과 예산 수립에 바로 쓰인다

Target Variable 정의 (도메인 기준)

- cycle_life = 방전 용량이 0.88Ah(공칭 1.1Ah의 80%, SOH 80% = ESS 교체 기준)에 도달한 사이클 수
- 모델 타깃은 $\log_{10}(\text{cycle_life})$, 예측 후 역변환해 MAPE 계산 (근거 Q1 : right-skewed 분포)

왜 초기 100 사이클만 쓰는가

- 100 사이클은 수명(392~1,935)의 약 5~26% 시점 → 운영 초기에 교체 계획 수립 가능
- 그 이후 데이터를 쓰면 예측 시점에 알 수 없는 미래 정보가 들어간다 (누수)

배치	역할	최종 셀
Batch 1 (2017-05-12)	학습 (정책 단위 CV + hold-out)	36
Batch 2 (2018-02-20)	테스트 (필수)	39
Batch 3 (2018-04-12)	추가 검증	44

성능 리포팅 계획

- Train (b1 CV), Valid (b1 hold-out), Test (b2) MAPE
- Gap : Train-Valid (과적합), Valid-Test (배치 간 일반화), Target(9.1%)-Test (원논문 대비)
- Batch 3 추가 검증과 Batch2-Batch3 Gap
- Test 오차는 일반 / newstructure 셀로 나눠 residual 분석

수명을 관측한 셀만 쓴다 : 46 / 47 / 46 → 36 / 39 / 44셀

ISSUE) 이번 데이터 버전(errorcorrect)은 원논문 처리 규칙과 맞지 않는 부분이 있다. 확인할 수 없는 값은 쓰지 않는다는 원칙으로 정제했다.

배치	원본	제거	최종	제거 사유
b1	46	10	36	EOL 미도달 : c0~c4 (마지막 QD 0.97~1.04Ah), c8, c10, c12, c13, c22 (0.91~0.97Ah)
b2	47	8	39	다른 실험 프로토콜 : VarCharge 4셀, SLOWCYCLE 4셀 (cycle_life 없음)
b3	46	2	44	EOL 미도달 : c23, c32 (2,189와 2,237 사이클에서도 미도달)

정제 원칙

- 인덱스 : summary와 Qdlin 배열 $j = \text{cycle} - 1$ (cycle 10 = j9, cycle 100 = j99). b1의 j0(cycle 1)은 0으로 채워진 더미
- EOL : 실험이 QD 0.880~0.881Ah에서 종료되므로 데이터에 기록된 cycle_life를 target으로 사용
- Outlier filtering : 9셀에서 단발성 QD 스파이크(최대 1.8Ah) → 셀 제거 대신 median filter(k=5)
- IR = 0 기록 (측정 누락, b2 6셀) → 결측 처리

원논문과 다르게 처리한 셀


- b1 c0~c4 : 원논문은 실험이 b2로 이어졌다고 보고 수명을 1,434~2,237로 보정. 원본 .mat의 barcode(셀 일련번호)를 대조한 결과 이 5셀은 b2 47셀 어디에도 없음 (b1은 EL1508004 계열, b2는 전부 EL1508007 계열) → 검증 불가하므로 학습에서 제외
- b3 c2, c37, c42, c43 : 원논문은 노이즈 채널로 제거. 우리 스파이크 점검(30mAh 초과)에 걸리지 않아 유지
- b3 c23, c32 : b3에서 가장 오래 산 셀이라 제외하면 b3 분포가 실제보다 짧게 보인다 (우측 중도 절단)

[to modeling] b1 학습셋의 수명 범위가 534~1,074로 좁아져, 더 긴 수명(b2 최대 1,186, b3 최대 1,935)은 외삽이 필요하다.
→ 외삽 가능한 선형 계열 우선, DAY 2에 c0~c4 원논문 보정값을 넣은 경우와 민감도 비교

Q1. Cycle Life 분포는 어떻게 생겼는가?

배치마다 분포가 다르다 : b1은 좁고 대칭, b2와 b3는 right-skewed

ISSUE) Target Variable의 분포 형태와 장수명 / 단수명 비율, 배치 간 차이 확인



[describe]

배치	n	mean	median	IQR (Q1~Q3)	Upper / Lower whisker	skew → log	단명 <500	장수 >1000
b1	36	788	772	681~872	203 / 147	0.29 → -0.01	0%	13.9%
b2	39	566	472	440~509	678 / 48	1.57 → 1.30	71.8%	7.7%
b3	44	1,060	1,006	828~1,155	780 / 287	1.21 → 0.50	0%	52.3%

Upper whisker = $|Q3 - \max|$, Lower whisker = $|Q1 - \min|$ · skew > 0 = right-skewed (오른쪽 꼬리)


[plot]

- **b1** : mean $\approx$ median (788 vs 772), skew 0.29 → 거의 대칭. 단명 0%
- **b2·b3** : mean > median (+94, +54), Upper whisker가 Lower보다 훨씬 김 → **right-skewed**. 장수 쪽 수명 편차가 크고 불규칙
- IQR 기준 Outlier는 모두 장수 쪽 (b2 newstructure 9셀, b3 1,800 이상 3셀). 단명 Outlier는 없음
- log10 변환 후 skew 감소 (1.57 → 1.30, 1.21 → 0.50)

[to modeling] Target Variable은 **log10(cycle_life)** (right skew 완화, MAPE의 상대오차와 스케일 일치). 테스트 셀 상당수가 학습 수명 범위 밖 : b2의 76.9%가 b1 최소(534) 미만, b3의 36.4%가 b1 최대 (1,074) 초과 → **양방향 외삽**, 외삽 가능한 선형 계열 주력

수명을 2배로 가르는 것은 충전 정책이 아니라 실험 구조(newstructure)다

ISSUE) b2 장수 Outlier는 어디서 오는가? 단명 셀은 측정 오류인가? 학습 배치와 테스트 배치는 무엇이 다른가?



b2, 같은 충전 정책	일반	newstructure
4.8C(80%)-4.8C	484 (n=5)	872 (n=3)
5.2C(58%)-4C	478 (n=4)	962 (n=3)
5.6C(26%)-4.5C	448 (n=6)	991 (n=3)

[plot]

- b2 newstructure 9셀 = b2 장수 Outlier 9셀 전부. **b3는 100% newstructure, b1은 0%**
- newstructure 셀은 측정값에도 차이 : 초기 IR 0.0151 vs 0.0171Ω, dQ_logvar -4.23 vs -3.46 (b2 newstructure vs 일반)

셀 일련번호(barcode)로 본 배치 구성

- b2의 일반 셀과 newstructure 셀은 같은 번호대에 섞여 있다 → 같은 생산 묶음. 물리적 셀 차이보다 시험 스케줄(실험 구조) 차이로 추정
- b2와 b3는 같은 번호대(EL1508007), **b1만 EL1508004** → 학습 배치는 테스트 배치와 생산 로트도 다르다

배치별 최단 수명 셀 : 실제 열화 → 유지

- b1c20 (534) : b1에서 평균 C-rate가 가장 높은 5.4C(80%)-5.4C
- b2c19 (392) : 일반 구조 셀 (b2 일반 30셀 모두 392~514)
- b3c28 (541) : 2단계 5.9C 고전류 정책



세 셀 모두 QD 곡선은 정상이고 dQ_logvar가 배치 median보다 큼 → 측정 오류가 아니라 조건으로 설명되는 실제 열화

[to modeling] 학습(b1)에 없는 실험 구조와 생산 로트가 테스트(b2, b3)에 있다. 같은 로트 안에서도 실험 구조만으로 수명이 약 2배 달라진다.

→ Outlier는 유지, Valid-Test Gap이 크게 나올 위험을 명시, 구조 차이가 드러나는 측정 피쳐(ΔQ) 중심, Test residual을 일반 / newstructure로 나눠 분석

Capacity Fade는 가속형 : 수명의 약 75% 지점(Knee point) 이후 약 10배 빨라진다

ISSUE) 열화 속도는 일정한가, 가속되는가? 초기 사이클의 방전 용량(QD)만으로 수명을 구분할 수 있는가?



[plot]

- cycle 1~100 : 모든 셀이 1.06~1.11Ah에서 거의 겹친다 → 초기 상태 차이 거의 없음
- **가속형 열화** : Knee point 이전 기울기 $-61 \sim -104 \mu\text{Ah}/\text{cycle}$ → 이후 $-685 \sim -1,336$ (median 약 10배)
- Knee point = 수명의 75~79% (b1 579, b2 343, b3 820 cycle). 정규화 곡선 형태는 세 배치가 같다

[describe]

- cycle 10→100 용량 변화 median : $-1.3 / +0.4 / -1.1 \text{ mAh}$ → 공칭 1,100mAh의 약 0.1%
- log 수명과 r : b1 $r=+0.55$, **b2 $r=-0.24$** , b3 $r=+0.44$ → b2 일반 셀의 70%는 초기 용량이 오히려 증가해 **부호가 뒤집힌다**
- Knee point는 EOL까지의 곡선에서 찾으므로 수명과 비례하는 것이 당연 → 초기 신호로는 쓸 수 없다



[to modeling] 100 사이클은 Knee point보다 한참 앞이라 QD 값만으로는 차이를 확인할 수 없고, 용량과 수명의 관계는 배치마다 뒤집힌다.

→ 용량 절대값과 감소량은 주력에서 제외, 방전 곡선의 **형태 정보($\Delta Q(V)$)** 확인 필요 (Q3)

Q3. $\Delta Q(V) = Q_{100}(V) - Q_{10}(V)$: 초기 사이클에서 차이가 보이는가?

용량 숫자에는 없던 차이가 방전 전압 곡선의 모양에는 있다

ISSUE) 100번째와 10번째 사이클의 방전 곡선(Qdlin) 차이에 수명 신호가 있는가? 장수 셀과 단명 셀의 ΔQ 형태는 어떻게 다른가?



[plot] 장수 vs 단명

단명 셀일수록 ΔQ 가 깊고 넓게 파인다 (최저점 단명 -36~-66mAh, 장수 -17~-29mAh). 가장 크게 갈리는 구간은 **2.9~3.0V** (최소값 위치 median b1 2.93, b2 2.96, b3 2.90V)로 세 배치가 같다.

[plot] b2 : 두 무리

곡선이 깊은 무리(일반 단명 셀)와 얇은 무리(newstructure 셀)로 나뉜다. Q1에서 본 실험 구조 차이가 ΔQ 에도 그대로 나타난다.

[plot] b3 왜곡, b1 스파이크


b3는 3.1V 부근에 양(+)의 돌출 → Qdlin 시작점 정렬 왜곡으로 추정 (과제 문서 경고와 일치). b1 장수 셀 하나에 단일 스파이크. 최소값보다 분산 기반 통계량이 덜 민감하다.

[to modeling] 100 사이클(수명의 5~26%) 시점의 방전 곡선 형태만으로 장수와 단명이 갈린다 → 예지 보전(PdM)이 가능하다.

→ 곡선 전체의 패임을 요약하는 **분산 기반 통계량**을 주력 파생변수로, min 기반 피쳐는 노이즈 리스크로 보조 취급

log Var(ΔQ)는 세 배치 모두에서 수명과 $r = -0.76 \sim -0.92$

ISSUE) $\Delta Q(V)$ 를 어떤 통계값으로 요약해야 하고, 그 관계가 배치가 바뀌어도 유지되는가?



[plot]

- 원논문의 핵심 결과(log Var 단일 피쳐)가 세 배치에서 모두 재현된다
- 배치별로 따로 맞춘 회귀 기울기는 비슷하다 (-0.30, -0.33, -0.31). 그런데 **b2만 절편이 아래로 이동** → 같은 dQ_logvar(-3.5)에서 b2 셀의 수명이 약 22% 짧다 (b1 635 vs b2 496)
- dQ_logvar 범위 : b1 -4.18~-3.35, b2 -4.45~-3.09, b3 -5.10~-3.45 → b2의 44%, b3의 48%가 b1 범위 밖 = **피쳐 값도 외삽**
- skew와 kurtosis는 배치마다 부호가 뒤집혀 불안정하다
- b3가 -0.76으로 가장 약하다 → 곡선 시작점 왜곡의 영향으로 추정

[describe]

ΔQ 통계량 (r with log10 life)	b1	b2	b3	전체
dQ_logvar = log10 Var	-0.84	-0.92	-0.76	-0.90
dQ_logmin = log10 min	-0.82	-0.90	-0.74	-0.88
dQ_mean	0.80	0.79	0.72	0.85
dQ_skew / dQ_kurt	-0.43 / 0.00	-0.13 / -0.66	0.19 / 0.26	≈ 0


[to modeling] 배치가 바뀌어도 방향과 기울기가 유지되는 신호는 ΔQ 계열이다. 다만 배치 간 수준 차이(절편)는 ΔQ 만으로 다 설명되지 않는다.

→ dQ_logvar를 주력 피쳐로, 원논문 방식의 단일 피쳐 선형 모델을 베이스라인으로, 절편 이동은 리스크로 관리 (residual 분석)

Q4. 충전 조건(C-rate)과 수명의 관계는?

고속충전은 b1에서만 수명을 줄인다 : b2와 b3는 모든 정책의 평균 C-rate가 4.8C로 같다

ISSUE) 충전 프로토콜별 평균 수명은? 고속 충전 셀이 정말 수명이 짧은가? 충전 전류 패턴과 열화 속도는 연관되는가?



[plot]

- **b1** : 0~80% 평균 C-rate와 $r = -0.59$. 상위 25% 고속충전 셀 평균 수명 736 vs 하위 25% 900 → 고속충전 셀이 실제로 짧다
- **충전 전류 패턴과 열화 속도** : b1에서 평균 C-rate와 Knee point 이전 열화 속도 $r = 0.70$ (Spearman 0.56, 5.4C 제외 시 0.55). 1단계 최대 전류 C1과는 -0.16 → 순간 최대 전류보다 **평균 충전 부하**가 열화 속도를 좌우
- **b2, b3** : 정책 19종(b2 12, b3 8, 1종 공유)이 모두 80%까지 약 10분 충전(4.79~4.81C)으로 설계 → C-rate 분산이 없다 ($r = 0.35 / -0.02$)

[describe]

- 정책 평균의 설명력(R^2) b1 89%, b2 94%, **b3 57%**. 같은 정책 안 max/min median 1.11배, 최대 2.38배 (b3 5C(67%)-4C : 813~1,935)
- C-rate와 평균 온도 $r = -0.20 \sim 0.14$ → "고속충전 → 발열 → 열화" 경로는 약하다
- **충전시간의 부호 반전 = 교란** : 초기 충전시간과 log 수명 r : b1 +0.57, **b2 -0.94**, b3 +0.60. b2의 -0.94는 newstructure 셀이 섞여 생긴 교란 → b2 일반 셀만 보면 $r = -0.25$


[to modeling] 충전 조건의 효과는 C-rate가 변하는 b1에서만 보이고, 테스트 배치에서는 정보가 없거나 교란된다.

→ 정책 변수(C1, Q1, C2, avgC_80)와 충전시간 제외, 같은 정책 셀이 train과 valid에 나뉘지 않게 **정책 단위 분할**

Q5. 상관관계 : 어떤 신호가 수명과 연관되어 있는가?

Batch 1만 보면 유망한 피쳐 상당수가 Batch 2에서 뒤집힌다

ISSUE) 초기 사이클 피쳐와 cycle life의 상관계수, 가장 강한 관계, 배치가 바뀌어도 유지되는가? 다중공선성(멀티콜리너리티)은?



피쳐별 log10 수명과의 Pearson r (배치별 막대). 전체 21개 피쳐 표와 피쳐 간 상관 heatmap은 노트북 01_EDA 참고

[correlation]

공선성 쌍 (b1)

	r
dQ_logvar ↔ dQ_logmin / dQ_mean	0.996 / -0.971
QD_2 ↔ QD_icpt_2_100	0.998
QD_100_m10 ↔ QD_slope_2_100	0.992
chargetime ↔ avgC_80	-0.995
Tmax ↔ Trange / Tavg ↔ Tmax	0.98 / 0.91

- 가장 강한 관계 : dQ_logvar (b1 -0.84, 세 배치 최소 |r| 0.76)
- VIF (b1, 후보 11개 동시 투입) : dQ_logvar 569, dQ_logmin 550, avgC_80 376, chargetime 322 → 다중공선성 심각
- 온도는 b1 |r| < 0.2이고 배치마다 부호 반전 (Tavg : -0.16 / +0.39 / -0.02)
- b1에서 |r| > 0.5인 피쳐 8개 중 4개가 b2에서 부호 반전

[to modeling] 세 배치에서 부호가 일관된 강한 신호는 ΔQ 계열뿐이고, 그 셋은 사실상 같은 정보다. b1 하나로 고른 피쳐는 테스트에서 실패한다.
→ 배치 일관성(부호 동일 + 최소 |r| ≥ 0.2)을 1차 기준으로 선택, 공선성 그룹은 대표 1개 + L1/L2 규제

후보 21개 → 주력 2개 : "배치가 바뀌어도 유지되는 신호"만 남긴다

기준) ① 세 배치에서 부호 일관 ② 최소 $|r| \geq 0.2$ ③ 공선성 그룹($|r| \geq 0.8$)당 대표 1개 ④ 학습 셀 36개이므로 소수 피쳐. 모든 피쳐는 cycle 2~100 측정값, 표준화는 학습 데이터로만 fit

그룹	피쳐 (파생변수)	r (b1 / b2 / b3)	① 일관	② 최소 r	③ 공선성	판정	근거
ΔQ(V)	dQ_logvar = log10 Var(Q ₁₀₀ -Q ₁₀)	-0.84 / -0.92 / -0.76	✓	0.76	ΔQ 그룹 대표	채택 (주력)	Q3, Q5
	dQ_logmin, dQ_mean	-0.82 / -0.90 / -0.74 등	✓	0.74 / 0.72	logvar와 $ r \geq 0.97$	셋 C에서만	Q5 VIF
	dQ_skew, dQ_kurt	-0.43 / -0.13 / +0.19 등	✗	—	—	제외	Q3
용량	QD_slope_91_100 (cycle 91~100 기울기)	0.54 / 0.30 / 0.46	✓	0.30	용량 그룹 대표 · dQ_logvar와 -0.54 (VIF 1.41)	채택 (보조)	Q2, Q5
	QD_2, QD_icpt, QD_slope_2_100, QD_100_m10	b2에서 부호 반전	✗	—	상호 0.99	셋 C에서만	Q2
온도	Trange_mean	-0.16 / -0.24 / -0.15	✓	0.15	Tmax와 0.98	제외 (② 미달)	Q4, Q5
	Tavg, Tmax	Tavg -0.16 / +0.39 / -0.02	✗	—	VIF 23~144	제외	Q4, Q5
저항	IR_2, IR_min, IR_100_m2	0.35 / -0.57 / 0.17 (IR_min)	✗	—	b2 결측 6	제외	Q1, Q5
충전	avgC_80, C1, Q1, C2	-0.59 / 0.35 / -0.02 (avgC)	✗ (C2 ✓)	C2 0.11	테스트 배치에서 avgC 상수	제외	Q4
	chargetime_2_6	0.57 / -0.94 / 0.60	✗	—	avgC와 -0.995	제외 (교란)	Q4

피쳐셋 A : Variance (베이스라인)

dQ_logvar 1개. 원논문 variance 모델 재현

피쳐셋 B : 주력

dQ_logvar + QD_slope_91_100. 기준 ①~④를 모두 통과한 피쳐만 사용 (VIF 1.41)

피쳐셋 C : 원논문 Discharge 재현 (비교)

B + dQ_logmin, dQ_mean, QD_2, QD_slope_2_100, QD_icpt_2_100. "부호 반전 피쳐가 b2 성능을 떨어뜨린다"는 가설 검증용

모든 설계 결정은 EDA 발견에서 나온다

읽는 법) 발견 → 왜 문제인가(시사점) → 그래서 무엇을 정했나(설계 결정)

	EDA 발견	시사점	설계 결정
정제	b1 c0~c4는 barcode상 이어진 셀이 없어 수명 검증 불가	학습 수명 범위 534~1,074로 좁아짐	제외, DAY 2에 원논문 보정값 민감도 분석
Q1	b2, b3 right-skewed (skew 1.57, 1.21), Upper whisker가 Lower의 2.7~14배	장수 셀에서 오차가 커진다	log10(cycle_life) 타깃, 역변환 후 MAPE
Q1	b2의 76.9%가 b1 최소(534) 미만, b3의 36.4%가 b1 최대(1,074) 초과	타깃의 양방향 외삽	외삽 가능한 선형 계열 주력, 트리는 비교군
Q1	같은 정책도 newstructure면 수명 약 2배, b1에는 없음	배치(실험 구조, 로트) 효과	측정 피처(ΔQ) 중심, residual을 구조별로 분석
Q2	cycle 100까지 용량 변화 약 0.1%, b2에서 상관 부호 반전	용량 수치로는 조기 예측 불가	용량 절대값과 감소량은 주력에서 제외
Q3	dQ_logvar r = -0.84 / -0.92 / -0.76, 기울기 동일	배치를 넘어 유지되는 핵심 신호	dQ_logvar 주력, 단일 피처 선형 베이스라인
Q3	b2 절편 이동, dQ_logvar의 b2 44% · b3 48%가 학습 범위 밖	피처 공간에서도 외삽	Valid-Test Gap을 배치 효과로 해석
Q3	b3 곡선 시작점 왜곡, 단일 스파이크	min 기반 피처는 노이즈에 취약	분산 기반 피처 우선, b3 분리 보고
Q4	b2와 b3는 평균 C-rate 4.8C 고정, 충전시간은 교란으로 반전	충전 피처는 테스트에서 정보 없음	정책 변수와 충전시간 제외
Q4	정책 평균 설명력 89~94% (b1, b2), 같은 정책 셀 2~8개씩 존재	같은 정책 셀이 나뉘면 누수	정책 단위 GroupKFold와 그룹 hold-out
Q5	b1에서 유망한 피처 다수가 b2에서 부호 반전	b1 단독 피처 선택은 과적합	배치 일관성 기준으로 피처 선정 (셋 B), 셋 C로 가설 검증
Q5	ΔQ 끼리 $ r \geq 0.97$, VIF 550 이상	계수 불안정	그룹 대표 1개 + ElasticNet 규제
공통	b1 36셀 / 20개 정책 → Valid는 7~9셀	단일 분할 결과는 운에 좌우	분할 20회 반복으로 안정성 확인, 차이가 작으면 단순한 모델

소표본, 외삽, 공선성에 맞춘 규제 선형 모델 중심 전략

목적) 셀별로 / 초기 100 사이클 데이터를 바탕으로 / EOL까지의 총 사이클 수(log10)를 예측한다

후보 모델	알고리즘 관점	데이터 관점 (EDA 근거)
단일 피처 선형회귀 베이스라인 (셋 A)	원논문 variance 모델. 해석이 가장 쉽고 외삽 가능	Q3 dQ_logvar와 log 수명이 세 배치 모두 직선 관계 ($ r \geq 0.76$, 기울기 동일)
ElasticNet 주력 (셋 B · C)	L1(계수 0 만들기) + L2(계수 축소)를 함께 써서 소표본에서 계수를 안정화. 선형이라 외삽 가능	학습 36셀(Q1) → 과적합 억제 필요. 셋 B는 VIF 1.41로 공선성이 낮지만, 같은 모델로 셋 C(VIF 550 이상, Q5)까지 공정 비교 가능
Ridge / Lasso 비교	규제 방식 단독 비교 (L1은 공선성 그룹에서 1개만 남김)	Q5 공선성 그룹이 있을 때 어느 규제가 안정적인지 확인
Gaussian Process Regression 비교	소표본 비선형 학습, 예측 구간(불확실성) 제공	외삽 구간(Q1, Q3)의 불확실성을 교체 시점 의사결정에 함께 제공
SVR (RBF) · 얇은 RandomForest 대조군	비선형·상호작용 확인 (트리 depth 2~3으로 제한)	Q3에서 관계가 선형으로 보였는지 반증 확인. 트리는 학습 범위($\leq 1,074$) 밖 예측 불가 → b2 단명, b3 장수에서 약할 것으로 예상

탐색 범위 (하이퍼파라미터)

- ElasticNet : $\alpha 10^{-4} \sim 1$ (9단계), l1_ratio 0.1 / 0.5 / 0.9 · Ridge $\alpha 10^{-3} \sim 10^2$ · Lasso $\alpha 10^{-4} \sim 10^{-0.5}$
- SVR : C 0.3~10, γ scale / 0.1 / 1, ϵ 0.01 / 0.03 · RF : depth 2~3, min_leaf 2 / 4
- GPR : Constant $\times$ RBF + White kernel (noise 하한으로 학습 데이터 암기 방지)

쓰지 않는 선택지

- 딥러닝 : 학습 셀 36개로는 파라미터 수에 비해 데이터가 절대적으로 부족, 정비 의사결정(PdM)에는 피처 단위 설명력이 중요
- Classification : 550 사이클 기준이면 b1은 97.2%가 장수, b2는 23.1%만 장수 → 라벨이 배치마다 한 쪽으로 쏠림

최종 모델은 Batch 1 안에서만 고른다 : Test는 선택에 쓰지 않는다

ISSUE) 후보 조합(피쳐셋 3 × 모델 7 = 21개) 중 하나를 어떻게 고르는가? Valid 셀이 7~9개뿐인 소표본에서 선택을 어떻게 믿을 수 있는가?

모델 선택 규칙

- ① **Test(b2, b3)는 선택에 사용하지 않는다** — 보고만 한다
- ② 선택 대상 : 피쳐셋 A, B × 모델 7종. 셋 C는 가설 검증용 비교군으로 선택 대상에서 사전 제외 (배치 불일관 피쳐 포함, Q5)
- ③ 기준 : **(Train CV MAPE + Valid MAPE) / 2** 최소
- ④ 1·2위 차이가 분할 변동(20회 반복의 표준편차)보다 작으면 **피쳐 수가 적은 단순한 모델**을 택한다 (외삽·소표본 리스크, Q1)

Gap 해석 계획 (MAPE, 양수 = 오차 증가)

- Train – Valid : 과적합 (피쳐 2개와 규제로 통제)
- Valid – Test : 배치 효과(절편 이동, newstructure)와 외삽 (Q1, Q3)
- Target(9.1%) – Test : 분할 방식과 셀 구성 차이
- Test residual을 일반 / newstructure로 나눠 **무작위 오차인지 일괄 편향인지** 구분

구분	검증 설계
Valid	Batch 1 내 정책 그룹 단위 hold-out 약 20% (GroupShuffleSplit). 같은 정책 셀이 train과 valid에 나뉘지 않음 (Q4)
Train	hold-out을 뺀 나머지 Batch 1에서 정책 단위 GroupKFold(5) CV 평균 (하이퍼파라미터 탐색 포함)
Test	선택된 설정으로 Batch 1 전체 재학습 → Batch 2 (필수), Batch 3 (추가)
안정성	hold-out 분할 seed를 20회 바꿔 Valid MAPE의 평균 ± 표준편차 확인
민감도	b1 c0~c4를 원논문 보정 수명으로 포함한 경우와 비교

전처리

- QD median filter(k=5), IR 0 → 결측
- StandardScaler는 학습 데이터로만 fit (Pipeline으로 CV fold마다 재학습)
- 평가 지표 : log10 예측값을 역변환한 뒤 MAPE

원논문 9.1%보다 성능이 낮을 이유를 EDA로 미리 설명한다

ISSUE) 배치 단위 분할과 데이터 버전 차이로 원논문 조건과 다르다. 성능 Gap의 원인을 사전에 정리한다.

리스크	근거 (EDA)	대응
① 양방향 외삽	b1 수명 534~1,074인데 b2의 76.9%는 534 미만, b3의 36.4%는 1,074 초과. dQ_logvar도 b2 44%, b3 48%가 b1 범위 밖	선형 계열 주력, GPR 예측 구간으로 불확실성 표시, Valid-Test Gap을 외삽으로 해석
② 실험 구조와 생산 로트 차이	b1은 일반 구조, EL1508004 로트. b2와 b3는 EL1508007 로트이고 newstructure 포함(b3는 100%). 같은 로트 안에서 구조만으로 수명 약 2배, b2는 같은 dQ_logvar에서 수명 약 22% 짧음	조건 피처를 빼고 ΔQ 중심, Test residual을 일반 / newstructure로 나눠 보고
③ 분할 방식 차이	원논문은 b1과 b2를 섞어 번갈아 학습과 테스트로 나눴지만, 과제는 배치 단위로 나눈다	Target-Test Gap 해석에 명시
④ 셀 구성 차이	원논문 학습 41 / 1차 테스트 43 / 2차 테스트 40셀 vs 이번 36 / 39 / 44셀 (c0~c4 제외, b3 노이즈 채널 4 유지)	직접 비교의 한계를 리포트에 명시, c0~c4 보정값 포함 시 민감도 분석
⑤ 소표본 선택 불안정	b1 36셀, 정책 20개 → Valid 7~9셀	분할 20회 반복, 차이가 작으면 단순한 모델 선택
⑥ Batch 3 왜곡과 중도절단	3.1V 부근 ΔQ 양수 돌출, dQ_logvar 상관 -0.76으로 가장 약함. 가장 오래 산 2셀(2,189, 2,237 사이클 이상)은 수명 미관측으로 제외	분산 기반 피처 우선, b3는 추가 검증으로 분리 보고

ESS 관점 같은 셀이라도 운전 구조나 생산 로트가 바뀌면 수명이 약 2배 달라질 수 있다.
운영 시사점 다른 사이트나 새 로트에 적용할 때는 그 사이트의 초기 데이터로 재보정하는 절차가 필요하다.